



Nombres: Sebastian Garcia Rios, Adrian Jaret Rendon Rios

Profesor: Zuriel Mora Felix

Unidad: 3

Proyecto: **Optimización de Riego con Enjambre de Partículas**

El presente trabajo aborda el desafío de la optimización de recursos hídricos en la agricultura, específicamente en la región de Guasave, Sinaloa.

Dada la variabilidad en la topografía, tipos de cultivo y condiciones del suelo, se propuso un método de inteligencia artificial para determinar la ubicación óptima de 5 sensores de humedad.

Se implementó un algoritmo de Optimización por Enjambre de Partículas (PSO), modelando el problema como un espacio de búsqueda multidimensional de 25 dimensiones (5 sensores x 5 variables).

El objetivo fue minimizar una función de costo basada en la distancia euclidiana cuadrática, similar a un problema de clustering.

Los resultados del enjambre (50 partículas, 200 iteraciones) convergieron exitosamente a un costo final de 25.53, identificando 5 coordenadas geoespaciales óptimas.

El análisis de las gráficas de funcionamiento y convergencia demuestra la eficacia del algoritmo para manejar las diversas configuraciones del terreno.

Se concluye que PSO es una herramienta robusta y viable para la agricultura de precisión.



La Agricultura de Precisión (AP) es un enfoque de gestión agrícola que utiliza tecnologías de la información, geolocalización (GPS), sensores y análisis de datos (Big Data) para observar, medir y gestionar la variabilidad espacial y temporal dentro de un campo.

El objetivo principal de la AP es optimizar la toma de decisiones, aumentando la eficiencia de los recursos, mejorando la sostenibilidad y maximizando la productividad.

En lugar de tratar un campo entero como una unidad homogénea, la AP reconoce que diferentes zonas del campo tienen diferentes necesidades. Esto es especialmente crítico en la gestión del riego.

En un terreno como el de Guasave, donde coexisten diferentes cultivos (como Maíz, Tomate y Chile) y existe una alta variabilidad en las condiciones del suelo (como el aumento de la salinidad y la disminución de materia orgánica), aplicar una lámina de riego uniforme es ineficiente.

La AP permite un riego de precisión, donde se aplica la cantidad correcta de agua en el lugar y momento correctos.

Para lograr esto, es indispensable el uso de sensores que capturen dicha variabilidad. Sin embargo, la colocación de estos sensores no es trivial

El problema que aborda este proyecto es: ¿dónde colocar un número limitado de sensores para obtener la información más representativa de todo el sistema?

Inteligencia Artificial Bio-inspirada

Para resolver problemas de optimización como, recurrimos a la Inteligencia Artificial (IA) Bio-inspirada.

Esta es una rama de la computación que desarrolla algoritmos y métodos de resolución de problemas inspirados en la observación de sistemas biológicos y el comportamiento social de la naturaleza.

Ejemplos clásicos incluyen los algoritmos genéticos (basados en la evolución darwiniana), los algoritmos de colonia de hormigas (basados en cómo las hormigas encuentran el camino más corto al alimento) y, el central de este estudio, la Optimización por Enjambre de Partículas, todos vistos en clase.

Estos algoritmos son conocidos por su robustez y su capacidad para manejar problemas de optimización no lineales y multidimensionales, donde los métodos tradicionales fallarían o serían computacionalmente prohibitivos.



La Optimización por Enjambre de Partículas (PSO), propuesto originalmente por James Kennedy y Russell Eberhart en 1995, es el algoritmo central de este estudio. Es una técnica de optimización metaheurística inspirada en el comportamiento social de las parvadas de aves o los cardúmenes de peces cuando buscan alimento.

En lugar de una sola solución, PSO utiliza una población (un "enjambre") de "partículas" que "vuelan" a través de un espacio de búsqueda multidimensional para encontrar la mejor solución posible.



Conceptos Clave del Algoritmo PSO:

- **Partícula:** En el contexto de este proyecto, una partícula no es un sensor. Una partícula es una solución candidata completa. Dado que buscamos 5 sensores en un espacio de 5 dimensiones, cada partícula es un vector que define las posiciones de esos 5 sensores (un vector de 25 dimensiones).
- **Enjambre:** Es el conjunto de todas las partículas (en nuestro caso, 50) que exploran el espacio de búsqueda simultáneamente y comparten información entre sí.

- **Posición y Velocidad:** Cada partícula tiene dos propiedades principales:
 1. **Posición (x):** Su ubicación actual en el espacio de búsqueda (su solución candidata actual).
 2. **Velocidad (v):** La dirección y magnitud de su movimiento. La velocidad se actualiza en cada ronda (iteración) y "empuja" a la partícula hacia mejores zonas del espacio de búsqueda.
- **Inteligencia Colectiva (pbest y gbest):** El movimiento de las partículas no es aleatorio. Se guía por dos factores clave de "memoria" o "inteligencia colectiva":
 1. **Mejor Personal (pbest):** Es la "memoria" de la partícula. Es la mejor posición (la solución con el costo más bajo) que *esa partícula* ha encontrado en toda su historia.
 2. **Mejor Global (gbest):** Es la "conciencia social" del enjambre. Es la mejor posición encontrada por cualquier partícula del enjambre hasta ese momento.

En cada iteración, cada partícula ajusta su velocidad (y por ende su próxima posición) para moverse en una dirección que es un promedio ponderado de tres componentes:

1. Su inercia actual (seguir en la dirección que ya llevaba).
2. La dirección hacia su Mejor Personal (pbest) (su propia "experiencia").
3. La dirección hacia el Mejor Global (gbest) (la "experiencia" del grupo).

Este equilibrio entre la "confianza personal" (factor c_1) y la "confianza social" (factor c_2) permite al enjambre explorar eficientemente el espacio (evitando óptimos locales) y, finalmente, "converger" hacia la mejor solución global encontrada.

Metodología y Diseño del Algoritmo

Para resolver el problema de optimización, se diseñó una metodología computacional que traduce el problema agrícola real a un modelo matemático que el algoritmo PSO puede solucionar.

Esta sección detalla el proceso, desde la preparación de los datos hasta la configuración final del enjambre.

Fuente y Preparación de Datos

El algoritmo se alimentó de un conjunto de datos simulados de 100 puntos de muestreo, representativos de la región de Guasave. Cada punto de dato contenía información sobre el cultivo, condiciones del suelo y geolocalización.

1. Selección de Variables: Basado en los objetivos del proyecto de considerar la topografía, los cultivos y el suelo, se seleccionaron 5 variables clave (o "features") de la tabla de datos para definir el estado de cada punto:

1. Latitud (Variable geoespacial)
2. Longitud (Variable geoespacial)
3. Elevación (m) (Variable topográfica)
4. Salinidad (dS/m) (Variable de suelo)
5. Humedad (%) (Variable de suelo)

Normalización de Datos (Pre-procesamiento): Este fue un paso metodológico crítico. Las variables seleccionadas operan en escalas drásticamente diferentes. Si se usaran "en crudo", el algoritmo de PSO, que se basa en distancias, le daría una importancia desproporcionada a las variables con rangos numéricos más grandes.

Para solucionar esto, se aplicó un MinMaxScaler de la librería scikit-learn. Esta técnica **normaliza** cada una de las 5 variables, re-escalando sus valores para que todos quepan en un rango uniforme de **[0, 1]**. Esto asegura que todas las variables sean tratadas con igual importancia durante el cálculo de distancias, permitiendo una optimización justa y equilibrada.

Modelado del Problema (Objetivo Específico 1)

El primer objetivo específico era "Modelar el problema... como un espacio de búsqueda multidimensional". Esto se logró de la siguiente manera:

- **Definición de Partícula:** En este modelo, una "partícula" no es un solo sensor. Una partícula representa una **solución candidata completa**.
- **Dimensiones del Problema:**
 - Se definió el número de sensores a encontrar como $N = 5$.
 - Se definió el número de variables que describen cada sensor como $D = 5$ (Lat, Lon, Elev, Sal, Hum).
- **Espacio de Búsqueda:** Por lo tanto, cada partícula (solución completa) es un **vector de 25 dimensiones ($N * D = 5 * 5$)**. El algoritmo PSO debe buscar en este espacio de 25 dimensiones el vector que represente la mejor configuración posible de 5 sensores.

Función de Aptitud (Costo)

El núcleo de la implementación es la función de aptitud (calcular_costo_total en el código). Esta función actúa como el "juez" que califica qué tan buena (o mala) es la solución de cada partícula. Dado que PSO es un minimizador, el objetivo es encontrar la partícula con el costo más bajo.

El problema se modeló como un problema de clustering (agrupamiento), similar al algoritmo K-Means:

1. Para una partícula dada, se "remodela" su vector de 25 dimensiones para obtener las 5 posiciones de los sensores en el espacio de 5D.
2. El "juez" itera sobre cada uno de los 100 puntos de datos normalizados.
3. Para cada punto de dato, calcula la distancia Euclidiana a cada uno de los 5 sensores propuestos.
4. Identifica la distancia al sensor más cercano (distancia_minima).
5. Suma el cuadrado de esta distancia (distancia_minima^2) a un "costo total" para esa partícula. Se usa el cuadrado para penalizar más fuertemente a las soluciones que dejan puntos de datos muy lejos de cualquier sensor.

6. El valor final de esta suma es el "costo" de la partícula. Una solución donde los 5 sensores están bien "centrados" entre los 100 puntos de datos tendrá un costo total bajo.

Configuración Experimental

Para ejecutar la optimización, se utilizaron las herramientas recomendadas por el proyecto, incluyendo Python, Visual Studio Code y la librería PySwarms.

El enjambre se configuró con los siguientes parámetros:

- **Algoritmo:** GlobalBestPSO de pyswarms. Se eligió este modelo porque su topología ("mejor global") permite una rápida convergencia al compartir la mejor solución encontrada entre todas las partículas del enjambre.
- **Número de Partículas (n_particles):** 50. Se utilizó un enjambre de 50 partículas para asegurar una buena exploración del vasto espacio de búsqueda de 25 dimensiones.
- **Número de Iteraciones (n_iteraciones):** 200. Se configuró el enjambre para "volar" durante 200 rondas, dando tiempo suficiente para que las partículas afinaran sus soluciones y convergieran.
- **Hiperparámetros (Opciones):** Se usaron los valores estándar recomendados en la literatura de PSO, que equilibran la exploración y la explotación:
 - 'w' (Inercia): 0.9 (impulso para seguir explorando)
 - 'c1' (Cognitivo): 0.5 (confianza en su mejor solución personal)
 - 'c2' (Social): 0.3 (confianza en la mejor solución del grupo)

```


'c:\Users\sebas\.vscode\extensions\ms-python.debugpy-2025.14.1-win32-x64\bundle\libs\debugpy\launcher' '62554' '--' 'c:\Users\sebas\Documents\PSO\optimizacionDeRiego.py'
PS C:\Users\sebas\Documents\PSO> popd
PS C:\Users\sebas\Documents\PSO>
PS C:\Users\sebas\Documents\PSO> c++; cd 'c:\Users\sebas\Documents\PSO'; & 'c:\Users\sebas\AppData\Local\Microsoft\WindowsApps\python3.11.exe' 'c:\Users\sebas\.vscode\extensions\ms-python.debugpy-2025.14.1-win32-x64\bundle\libs\debugpy\launcher' '55121' '--' 'c:\Users\sebas\Documents\PSO\optimizacionDeRiego.py'
--- 1. Herramientas importadas ---
--- INICIO DEL PROYECTO DE OPTIMIZACIÓN PSO ---
--- 2. Cargando datos del terreno... ---
--- 3. Preparando datos (Normalizando)... ---
--- 4. Configurando el enjambre PSO... ---
--- 5. ¡Optimizando! (50 partículas, 200 rondas)... ---
2025-11-04 10:23:36,706 - pyswarms.single.global_best - INFO - Optimize for 200 iters with {'c1': 0.5, 'c2': 0.3, 'w': 0.9}
pyswarms.single.global_best: 100% | 200/200, best_cost=25.5
2025-11-04 10:23:57,754 - pyswarms.single.global_best - INFO - Optimization finished | best cost: 25.537568534953632, best pos: [0.66283996 0.3
3208215 0.29074218 0.21551906 0.60847212 0.34615152
0.78556125 0.32067721 0.30587658 0.30986245 0.30809859 0.32274622
0.5803095 0.44006821 0.46630941 0.51906909 0.77835721 0.76219163
0.53527033 0.5457933 0.74735575 0.23357337 0.55492272 0.71969857
0.5174408 ]
--- 6. ¡Optimización terminada! Costo final: 25.537568534953632 ---

--- 7. Procesando la solución ganadora... ---


--- ❄️ ¡RESULTADO FINAL! UBICACIONES ÓPTIMAS ---

```

Curva de Convergencia (Cómo "aprendió" el enjambre)



Mapa Geoespacial: 5 Sensores Optimizados



Esta gráfica demuestra la **eficacia** del algoritmo para manejar las configuraciones del terreno. Se observa que las estrellas no siguen un patrón de cuadrícula simple; están posicionadas estratégicamente.

El algoritmo colocó los sensores en los centros de los conglomerados (clusters) de datos, asegurando que cada sensor monitoree un "vecindario" de puntos con características similares. Esto valida visualmente que la solución responde directamente a la distribución espacial y a las propiedades de los datos.

Discusión de Resultados: La Tabla 1 es fundamental. No solo provee las coordenadas geoespaciales (Latitud, Longitud), sino que revela el "perfil" para el cual cada sensor está optimizado.

Por ejemplo, el Sensor 2 se ha posicionado para monitorear una zona de baja elevación (22.7m) y notablemente baja humedad (17.4%).

En contraste, el Sensor 1 cubre una zona de baja elevación similar (21.6m) pero con una humedad mucho más alta (29.3%).

Esta "especialización" de los sensores demuestra que el algoritmo no se limitó a distribuir los sensores geográficamente, sino que encontró los "centroides" óptimos de las diferentes configuraciones de terreno presentes en los datos).

La Figura 2 es el **análisis de eficiencia** del algoritmo. Muestra la "calificación" (Costo Total) de la mejor solución encontrada por el enjambre en cada una de las 200 "rondas" (iteraciones).

Discusión (Eficiencia): Esta gráfica es la prueba de que el algoritmo "aprendió" y no simplemente devolvió un resultado al azar. Se pueden observar dos fases clave:

1. **Fase de Exploración (Iteraciones 0-50):** La curva muestra una caída drástica en el costo (de >30 a ~ 27). Esto indica que el enjambre pasó rápidamente de soluciones iniciales aleatorias (muy malas) a soluciones "buenas", explorando eficientemente el espacio de búsqueda.
2. **Fase de Explotación (Iteraciones 50-200):** La curva se "aplana" (converge). Esto significa que el enjambre dejó de hacer grandes saltos y comenzó a "afinar" la mejor solución encontrada, moviéndose en pasos pequeños hasta que ya no fue posible mejorar significativamente el costo.

La forma de esta curva demuestra que el algoritmo fue eficiente, encontró una solución óptima estable y convergió, cumpliendo con el objetivo de evaluar el desempeño del algoritmo.

CONCLUSION:

En conclusión, este trabajo demuestra que la Optimización por Enjambre de Partículas no es solo un concepto teórico, sino una herramienta práctica, robusta y eficaz para resolver problemas de optimización complejos en la agricultura de precisión.

La metodología desarrollada cumple con todos los requisitos del proyecto y entrega una solución tangible que puede mejorar significativamente la eficiencia del riego en la región de estudio.